고려대 세종 2026-2 기업연계형 캡스톤디자인 · 프로젝트 설명서

MA-BEMS

멀티에이전트 건물 에너지 관리 시스템
어떻게 동작하고, 무엇을 넣어 무엇을 얻는가

MA-BEMS는 가상 캠퍼스 **Helio Campus**(건물 4개 동, 태양광 500 kWp, 배터리 1,200 kWh, 전기차 충전기 6기)를 **6개의 AI 에이전트**가 15분마다 계획을 내고 코디네이터(v2)가 비용 기준으로 조율하며 운영하는 대시보드입니다. 같은 날씨·재실·전기차·수요반응 조건으로 기존 방식인 **룰 기반 BMS**를 나란히 돌려, 두 방식의 차이만으로 효과를 잽니다. 운영자는 화면에서 상황을 보고, AI 비서에게 자연어로 묻고, 비서가 낸 제어 제안을 직접 승인해 적용합니다.

17.4%
전력량요금 절감, 룰 기반 BMS 대비
±0.1은 8일 변동, 날씨 변동 10회 16.9 ± 0.2%

0분 vs 1,996분
피크 한도(1,000 kW) 초과 시간
8일 합계

960 vs 1,170 kW
최대 수전 전력 (일별 최대의 평균)

99.9% vs 100%
재실 구역 쾌적 유지율

8.0%
수전 예측 오차 CV(RMSE), 1시간 앞
(미래 날씨 미사용, 어제 같은 시각 9.7%)

62 / 66
AI 비서(v2.1) 실제 예상 질문, Claude 채점
(수정에 쓴 회귀 세트, 오답 0건)

수치는 모두 시뮬레이션 기준입니다: 9일 × 1분 단위로 돌려 1~8일을 채점합니다. ±는 그 8일의 일별 변동(95% 구간)이며, 입력을 바꾼 10회 실행의 구간은 따로 냅니다. 실제 계량 데이터로 보정하기 전 값입니다.

작성 기준일 2026-11-12 · 공개 사이트 sunghyunc.github.io/ma-bems · 원본 저장소 github.com/SungHyunC/ma-bems-project

1 한눈에 보기
2 시스템 구성
3 가상 캠퍼스와 요금
4 동작 방식
5 입력과 출력
6 성능 평가 결과
7 장점
8 단점과 한계
9 다음 단계
부록 폴더 구조 · 실행 방법 · 용어

1. 한눈에 보기

무엇을 하나

캠퍼스의 전력 사용을 설비별 전문 에이전트(냉난방·조명·태양광·배터리·전기차 충전)와 이들을 조율하는 코디네이터가 함께 운영합니다. 목표 순서는 ① **피크 한도를 넘지 않기** ② **사람이 있는 공간의 쾌적 유지** ③ **비용·탄소 줄이기**입니다.

왜 필요한가

기존 룰 기반 BMS는 시간표와 고정 설정으로 움직여 재실·날씨·요금 변화에 늦고, 냉방·배터리·충전기가 서로 모른 채 따로 동작합니다. 그래서 비싼 시간대 사용과 피크(최대 수요)가 커지고, 피크는 한전 기본요금을 최대 1년간 올립니다.

어떻게 푸나

- 실(방) 단위 재실 감지로 빈 방은 설정 완화·소등·대기전력 차단
- 배터리는 싼 밤에 충전, 비싼 시간·피크 근처에서 방전
- 코디네이터가 예측 수전을 한도의 94%와 비교하고, 넘는 양은 에이전트들이 가격을 붙여 내놓은 감축을 싼 것부터 채움
- 수요 예측·센서 고장 감지·수요반응(DR) 대응·전기차 충전 미루기

사람과 AI의 역할

- 운영자는 3D 화면과 결정 로그로 "누가, 왜" 했는지 봄
- AI 비서(로컬 Qwen3-8B 파인튜닝)가 실시간 데이터로 답하고 제어를 제안
- 제안은 운영자가 **적용**을 눌러야만 실행되고, 고장 경보도 승인 카드로 처리

지금 상태 (2026-11-12)

- 대시보드는 GitHub Pages에 공개돼 있고, 설치 없이 브라우저에서 시뮬레이션·에이전트·예측·고장 감지가 모두 동작합니다. 기본 코디네이터는 v2이고(`coord=v1`로 이전 동작 재현), 방 센서 없는 건물용 1단계 프리셋, 제안 영향 미리보기, 계량 CSV 그림자 모드가 들어 있습니다(4.4).
- **AI 비서 모델**: 파인튜닝 v2.2를 사용자가 2026-11-12에 채택했고 어댑터는 GitHub 릴리스 `ft-lora-v22`에 공개했습니다. 운영 PC 등록(합치기, GGUF Q8_0 변환, `ollama create`, `.env` 설정)도 같은 날 마쳐서 **공개 데모의 AI 탭은 v2.2가 답합니다.** 접근 키를 받은 사람만 쓸 수 있고 운영자 PC가 켜져 있어야 합니다.
- 시나리오 9종(평상시·폭염·흐린 날·수요반응 강화·한도 하향·퇴근길 EV·휴일·센서 고장·최악의 날)과 직접 조건 만들기가 들어 있습니다.
- 데모 영상(릴리스 `demo-2026-11-12`, 2분 36초)의 AI 장면은 클라우드 GPU에서 서빙한 v2.2 Q8_0 모델이 답했습니다. 공개 데모도 같은 어댑터로 만든 v2.2 Q8_0이 답하며, 돌리는 장비만 다릅니다.

한 줄 흐름: 무엇을 넣어 무엇을 얻나 (자세한 표는 5장)

넣는 것 (입력)

- 날씨·재실·요금표·피크 한도
- 수요반응 신호, 전기차 도착·출차
- 설비 사양(건물·태양광·ESS·충전기)
- 운영자 조작, AI 질문

→

하는 일 (처리)

- 1분 단위 시뮬레이션
- 15분마다 에이전트 조율·제어
- 같은 조건의 기준선과 비교
- 예측·고장 감지·AI 답변·제안

→

얻는 것 (출력)

- 실시간 상태와 결정 이유
- 비용·피크·쾌적 성과(기준선 대비)
- 경보·예측·고장 승인 카드
- AI 답변과 적용 카드

2. 시스템 구성

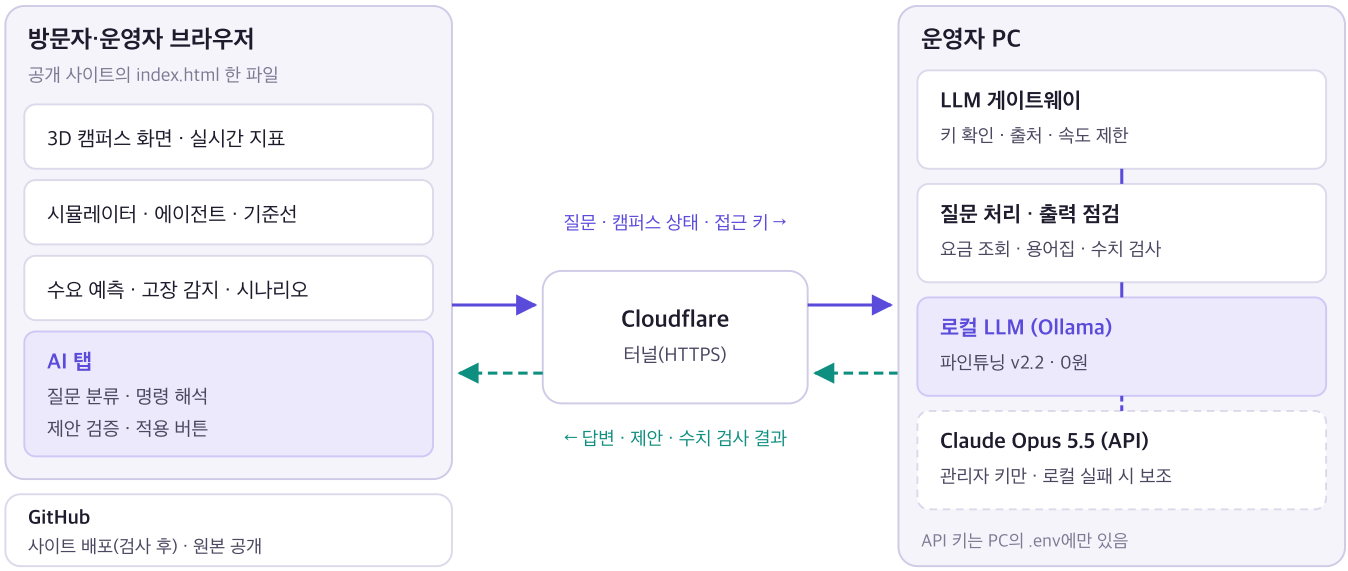


그림 1. 시스템 구성. 시뮬레이션과 에이전트는 모두 브라우저 안에서 돌고, AI 비서만 운영자 PC의 게이트웨이를 거칩니다.

구성 요소	하는 일	파일·기술
대시보드	3D 캠퍼스, 실시간 지표, 결정 로그, 시나리오·검증 탭, AI 탭	`index.html` 한 파일(약 1 MB), Three.js
시뮬레이터·에이전트	1분 단위로 날씨·재실·부하·설비를 계산하고, 15분마다 에이전트가 계획·조율·제어. 기준선 BMS를 같이 계산	브라우저 JavaScript (설치 불필요)
LLM 게이트웨이	AI 질문을 받아 모델을 고르고, 맥락 보강·수치 검사·출력 점검 후 돌려줌. 공개 API는 키·출처(CORS)·속도 제한, `/v1/chat/completions`는 관리자 키만	`server/mabems_server.py`, `assist.py`, `numcheck.py`
로컬 LLM	질문 답변, 브리핑, 설명, 제어 제안	Ollama + Qwen3-8B QLoRA 파인튜닝, Q8_0, 그래픽 메모리 약 10 GB. 지금 공개 데모는 v2.2(2026-11-12 등록)
배포	사이트 정적 배포, PC의 게이트웨이를 인터넷에 연결, 접근 키 관리	GitHub Pages(+Actions 검사), Cloudflare Quick Tunnel
평가 도구	헤드리스 Chrome으로 9일씩 돌려 지표 계산, LLM 평가	`eval/`, `build/`, `ft/`

3. 가상 캠퍼스와 요금

Helio Campus는 성격이 다른 건물 넷을 한 계약전력(피크 한도 **1,000 kW**)으로 묶은 캠퍼스입니다. 층마다 구역(존) 하나, 모두 **19개 구역** · **134개 실**이 있고, 실마다 재실 인원·온도·조명·콘센트·공조 상태를 따로 계산합니다.

건물	성격	층	옥상 태양광	특징
B1 오피스 타워	사무	8	90 kWp	평일 낮 재실, 회의실 예약·노쇼
B2 연구동	실험·연구	4	160 kWp	콘센트(장비) 부하가 큼
B3 기숙사	주거	5	120 kWp	저녁·밤 재실
B4 데이터센터	서버	2	70 kWp	IT 약 280 kW 상시, **냉방은 줄이지 않음**

설비	규모
태양광	옥상 440 kWp + 주차장 카포트 60 kWp = 500 kWp
ESS(배터리)	1,200 kWh, 최대 300 kW, 잔량 8% 아래로는 방전 안 함
전기차 충전기	6기: 완속 22 kW × 4, 급속 60 kW × 2
쾌적 범위	재실 구역 설정온도 ±1.5 °C

요금 구간(기본)	시간	단가
최대부하	13-19시	$0.28/kWh
중간부하	8-13시, 19-22시	$0.14/kWh
경부하	22-8시	$0.08/kWh
한전 프리셋: 일반용(을) 고압A 선택II 2026년판(여름 최대부하 15-21시, 222.3 ₩/kWh 등)과 BDG2 하루 부하 형태 불러오기 지원		

4. 동작 방식

4.1 1분 단위 시뮬레이션과 기준선

시뮬레이터는 한 번에 정확히 1분씩 나아갑니다. 같은 입력을 두 제어기에 동시에 넣어, 멀티에이전트 쪽과 룰 기반 BMS 쪽의 결과를 따로 집계합니다(반사실 그림자 실행, IPMVP Option D 방식의 시뮬레이션 비교). 그래서 날씨가 덥거나 사람이 많아서 생긴 차이가 아니라, **제어 방식의 차이만** 남습니다.

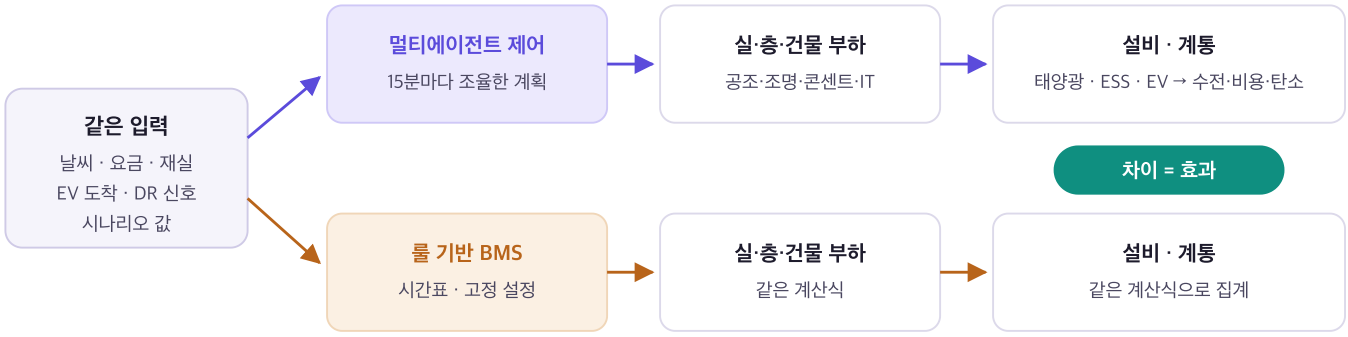


그림 2. 매 분 같은 입력을 두 제어기에 넣고 따로 집계합니다. 둘의 차이가 절감·피크 저감 수치가 됩니다.

룰 기반 BMS의 동작: 평일 시간표대로 공조·조명을 켜고, 배터리는 15~18시 고정 방전, 전기차는 꽂자마자 22 kW 충전, DR 신호에는 자동 대응 없음.

4.2 15분 주기 에이전트와 조율

여섯 에이전트가 15분마다 같은 다섯 단계를 반복합니다. 에이전트가 자기 설비의 계획(앞으로 예상되는 kW 변화)을 내면, 코디네이터(v2, 기본값)는 합친 예측 수전을 **한도의 94%**(DR 중에는 DR 목표)와 비교해 넘는 양을 먼저 사전 냉방 축소로 줄이고, 남는 양은 "몇 kW를 kWh당 얼마에 줄일 수 있다"는 에이전트들의 제안을 **싼 것부터** 채웁니다. 배정 뒤 가격이 10% 넘게 달라지면 다시 받아 최대 3번 되풀이합니다. v1(`coord=v1`)은 같은 94% 기준에서 정해진 순서로 줄였습니다(DR 때 ESS → EV → 조명 → HVAC).

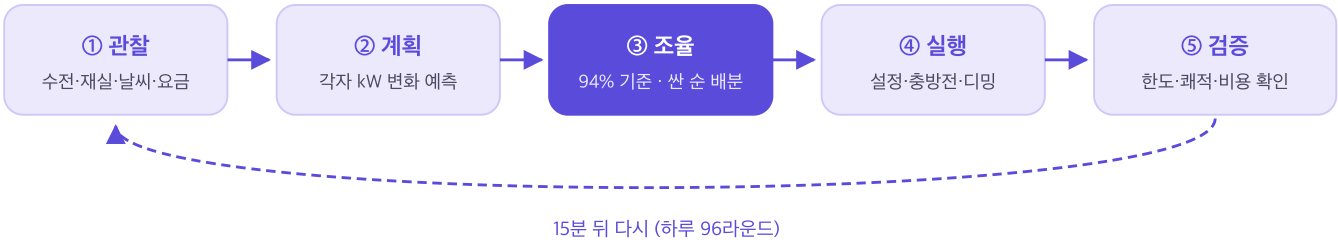


그림 3. 에이전트 주기. 조율 단계에서 코디네이터가 캠퍼스 전체 수전을 기준으로 각 계획을 조정합니다.

에이전트	평상시에 하는 일	피크·수요반응(DR) 때
코디네이터	계획 수집, 한도 94% 초과분을 싼 순으로 배정, 결정 로그 작성	DR 감축량도 싼 순으로 배정
HVAC(공조)	재실 구역 쾌적 유지, 빈 방 셋백, 피크 1시간 전 1 °C 사전 냉방	피크 중 1 °C 완화(이미 더운 건물은 0.4 °C), DR 때 +1.4 °C (데이터센터 +1.0 °C).
조명	10분 넘게 빈 방 소등·대기전력 차단, 주광 활용, 회의실 노쇼 예약 해제	피크 85%, DR 70% 디밍
태양광	지금의 맑음 지수로 1시간 앞 발전량 예측, 자가소비 극대화	예측을 코디네이터 계획에 반영
ESS(배터리)	경부하(밤)에 충전, 피크 전 보충, 피크 때 예측 기준선 초과분 방전	DR 공지 때 에너지를 남기고, DR 때 최대 방전
EV 충전	출차 시각에 필요한 충전량을 맞춤	피크(~19시)·한도 90% 초과 때 출차를 지키는 최소 전력으로

v2가 v1에 더한 것: ① **DR 공지**(60분 전): 배터리가 에너지를 남기고, 건물이 DR 45~10분 전 0.5 °C 미리 냉방하며, DR 뒤 공조(45분)·조명(30분)이 단계적으로 복귀. ② **예측 기반 배터리 운전**: 남은 에너지로 22시까지 버틸 수 있는 가장 낮은 수전 기준선을 예측(미래 데이터 없이)으로 계산. ③ **비용 기반 배분**: 가격은 ESS는 나중에 쓸 때의 가치(한도를 넘기면 가산), EV는 출차를 놓칠 위험, HVAC는 쾌적 이탈 위험, 조명은 고정값. 한도 94% 기준과 사전 냉방 축소는 v1에서 이어짐.

4.3 수요 예측과 센서 고장 감지

수요 예측

15분 단위로 4시간 앞 수전을 예측합니다. 미래 날씨를 쓰지 않는 릿지 회귀로, 입력은 어제 날씨 곡선과 오늘의 차이, 재실 시간표, 어제 같은 시각과 직전 시각의 값이며 지난 오차로 90% 범위를 냅니다. 정확도는 ASHRAE Guideline 14의 지표(CV(RMSE), NMBE)와 비교합니다.

센서 고장 감지(FDD)

5분마다 실 온도 센서를 읽어, 45분간 값이 그대로면 **고착**, 15분간 값이 없으면 **끊김**, 이웃 방·평소 추종 오차 양쪽에서 15분 넘게 1.6 °C 이상 벗어나면 **드리프트**로 봅니다. 운영자가 승인하면 그 방은 가상 센서로 제어됩니다.

4.4 시나리오

주소 뒤에 `?scn=`를 붙이거나 시나리오 탭에서 고르면 같은 캠퍼스를 다른 조건으로 처음부터 다시 돌립니다. 프리셋 9종(조건은 6.1)과, 기온·일사·재실·한도·DR·EV·고장을 직접 정하는 사용자 정의가 있습니다. 세 가지 기능이 더 있습니다. **1단계 프리셋**(`?ablate=ROOM`)은 에이전트가 건물·구역 단위로만 제어하게 해, 방 센서가 없는 건물에서 룰 기반 BMS와의 차이를 실시간 표로 봅니다. **영향 미리보기**는 AI 제안 카드에서 그 조치를 적용할 때와 안 할 때의 다음 60분(비용·최대 수전·쾌적)을 보여 줍니다. 비공개 시뮬레이터로 지금까지를 다시 돌려 두 갈래로 60분을 더 돌리며, 이 재현이 화면의 현재 수전·비용과 0.5% 안에서 맞지 않으면 수치를 내지 않습니다. **계량 CSV 그림자 모드**는 건물 전력 CSV(시각, kW; 1~14일)를 캠퍼스 규모로 키워 한전 2026 여름 평일 요금으로 계산해, 에이전트와 룰 기반 BMS의 차이를 시뮬레이션으로 추정합니다.

4.5 AI 운영 비서

AI 탭에 질문을 쓰면, 페이지가 먼저 질문의 종류를 가르고 그에 맞는 길로 보냅니다. 답이 정해져 있는 질문(요금 시간표, 용어 뜻, 인사, "한도를 넘을까?"·"넘었어?")은 모델 없이 데이터나 규칙으로 즉시 답하고, 해석이 필요한 질문만 언어모델이 답합니다. 모델에게는 질문과 함께 지금 캠퍼스 상태(JSON)가 가고, 답에 나온 숫자는 그 데이터와 자동으로 대조됩니다.

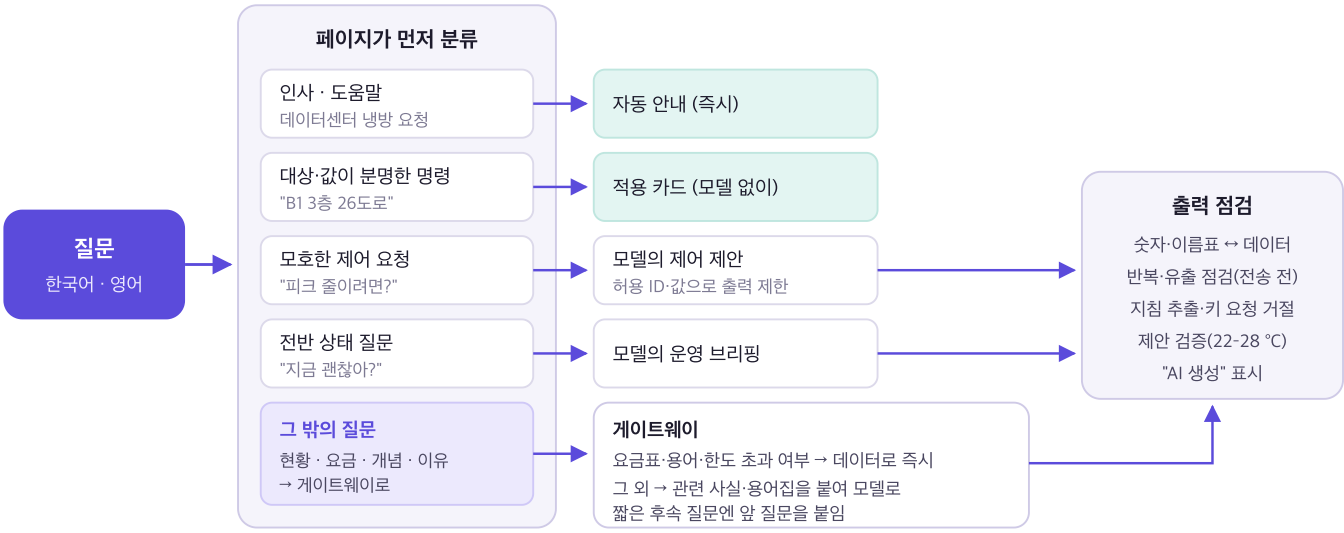


그림 4. AI 질문이 가는 길. 초록 상자는 모델 없이 답하는 경우입니다. 제어는 어떤 경우에도 운영자가 "적용"을 눌러야 실행됩니다.

모델과 학습

- Qwen3-8B를 QLoRA(r=16)로 파인튜닝. 정답은 시뮬레이터 데이터로 규칙이 만든 문장(비용 0원, 숫자 정확)
- v2.1: 질문 바꿔 쓰기, "한 문장으로" 지시, "바꿀 필요 없음" 예시를 보강. v2.2(2026-11-12 채택): 정의·층별·명령·후속 질문 유형과 현재 대시보드의 맥락 형식을 학습에 넣음. 둘 다 클라우드 GPU(H100)에서 학습, 어댑터는 릴리스 `ft-lora-v22`에 공개
- Q8_0으로 변환해 Ollama에서 운영, 8k 토큰 문맥. 지금 공개 데모는 v2.2(2026-11-12부터)

운영 원칙

- 로컬 모델 우선(데이터가 PC 밖으로 나가지 않음, 질문당 0원). Claude는 관리자 키 전용 보조
- 데이터에 없는 값은 "데이터에 없음"이라고 말함. 수치 검사에 걸리면 화면에 경고 표시. "한 문장으로" 같은 한 줄 요청은 검사를 거친 결론 한 문장만 남김
- 인공지능기본법 제31조를 고려해 모든 AI 답변에 "AI 생성" 표시

4.6 공개 배포와 보안

- **사이트**: GitHub Pages(무료). 올릴 때마다 Actions가 페이지 스크립트 문법, 설정 형식, 비밀값 유출을 검사한 뒤 배포합니다.
- **AI 연결**: 운영자 PC의 게이트웨이를 Cloudflare Quick Tunnel로 내보내고, 그 주소를 사이트의 `config.json`에 자동으로 씁니다.
- **접근 제어**: 모든 AI 호출에 접근 키(Bearer)가 필요합니다. 심사위원용 키는 로컬 모델만, 관리자 키는 Claude까지이고 OpenAI 호환 `/v1/chat/completions`도 관리자 키 전용입니다. 허용 출처(CORS), 키별 속도 제한, 동시 요청 2건 제한이 있고, 공개 포트로 파일을 내주지 않으며, PC 안의 로컬 포트는 다른 사이트의 Origin과 JSON이 아닌 Content-Type을 거절합니다. 모든 과제(질문·브리핑·설명·제안)에서 지침 추출을 검사하고, 스트리밍 글은 보내기 전에 유출 검사를 하며, 수치 검사는 숫자를 이름표(예: 피크·ESS)에 묶어 같은 항목의 값과 맞는지 봅니다. `server/test_gateway.py`의 테스트 11건이 이를 확인합니다.

5. 입력과 출력

5.1 시스템 전체

입력	내용	어디서
날씨	외기온도·일사량 하루 곡선	내장 여름 하루, 시나리오로 조정, CSV(실측 BDG2 등)
재실	건물 유형별 재실 곡선, 실별 인원, 회의실 예약	내장 곡선·시뮬레이션, CSV
요금·계약	계시별 단가, 피크 한도 1,000 kW	기본 요금표, 한전 2026 프리셋, `?limit=`
외부 신호	수요반응(DR) 요청(시각·감축량·시간), 전기차 도착·출차·필요 충전량	OpenADR 모사 신호, 세션 생성기, 시나리오
설비 사양	건물별 층수·공조·조명·콘센트·IT 용량, 태양광, ESS, 충전기	사이트 구성(TOPO)
운영자 조작	설정온도·조명 직접 조작, AI 제안 적용, 고장 경보 승인·기각, 시나리오·속도 선택	대시보드 화면
AI 질문	자연어 질문(한국어·영어), 빠른 버튼(브리핑·설명·제어 제안)	AI 탭

출력	내용	어디에
실시간 상태	캠퍼스 부하, 수전, 한도 여유, 태양광, ESS 충방전·잔량, EV, 요금 구간, 건물·층·실 상태	3D 화면, 상단 지표, 정보 패널
결정과 이유	에이전트별 조치와 이유("10분째 빈 방 → 소등"), 조율 라운드, 승인·되돌림	결정 로그
일간 성과	비용, 기준선 대비 절감률, 최대 수전, 한도 초과 분·kWh, 쾌적도, 탄소, DR 달성률, 빈 방 낭비 kWh	지표 카드, 비교 화면
경보	한도 초과, 쾌적 이탈, ESS 잔량 부족, 센서 고장(승인 카드)	경보 목록, 고장 카드
예측	4시간 앞 수전과 90% 범위, 피크 위험 시각	예측 차트·칩
AI 결과	답변, 운영 브리핑, 선택 대상 설명, 제어 제안 카드(적용 버튼), 수치 검사 결과	AI 탭
평가 자료	방법·결과·한계·출처, 시나리오별 측정값	검증·근거 탭, 시나리오 탭, `eval/results`

5.2 AI 비서의 입력과 출력

입력 (모델이 받는 것)

- **시스템 지시**: 역할, 근거 규칙(데이터에 있는 값만), 답 형식(결론 1문장 + 근거 2~4줄), 운영 우선순위
- **캠퍼스 상태 JSON**(약 7천 자): 시각·요금 구간·날씨, 캠퍼스 합계, 오늘 누적, 건물·층별 값, 빈 방 조명, EV, 시나리오, DR, 경보, 에이전트 상태, 최근 결정 8건, 일간 지표, 예측, 고장
- **질문**(+ 게이트웨이가 붙인 관련 사실·용어집, 짧은 후속 질문이면 앞 질문)

출력 (화면에 나오는 것)

- **답변 글**: 결론 한 문장과 근거 몇 줄. 아래에 "AI 생성", 사용 모델, 걸린 시간, "수치 검증 통과" 또는 "데이터에 없는 수치: …"
- **제어 제안 JSON**: `{summary, actions:[{type, target, value, expected_effect, reason}]}`. type은 존 설정온도·실 설정온도·실 조명. 페이지가 검증·보정(22-28 °C, 데이터센터 냉방 제외)한 뒤 카드로 보여 주고, **적용**을 누르면 시뮬레이터 명령으로 실행

예: "B1 3층 온도 몇 도야?" → "B1-F3 층은 24.6 °C(설정 24.4 °C)이고, 재실률은 95%입니다." / "빈 방 조명 꺼 줘" → 조명이 켜진 빈 방 카드(사람이 있는 방은 제외).

6. 성능 평가 결과

헤드리스 Chrome으로 대시보드를 9일씩 1분 단위로 돌리고 준비 구간(0일)을 뺀 1~8일을 채점했습니다.

항목	결과 (멀티에이전트 vs 룰 기반 BMS)
전력량요금 절감	**17.4 ± 0.1%** (코디네이터 v2 기본값, 1회 실행, ± = 8일 일별 변동). 날씨·재실을 바꾼 10회: **16.9 ± 0.2%** (실행 간 95% 구간). 튜닝 BMS 대비 17.3 ± 0.4%, 센서 BMS(재실 센싱·ESS 피크 제어·고정 DR 대응) 대비 **10.5 ± 0.3%**(10회 10.5 ± 0.2%, 그 BMS 쾌적 97.0%), DR 끔 15.0%, BDG2 부하 형태 + 한전 요금 14.7 ± 0.3%
최대 수전 / 한도 초과	일별 최대의 평균 960 vs 1,170 kW (기간 최대 960 vs 1,210) / 0분 vs 1,996분 (8일 합계). 10회: 969 vs 1,193 kW
쾌적 유지율	99.9% vs 100% (10회 99.7 vs 99.9%)
구성요소 기여 (%p)	실 단위 재실 제어 13.4 · ESS 3.6 · 공조 2.5 · 조명 0.9 · EV 0.1 · 코디네이터 배분 −0.16
코디네이터 (한도별 초과 전력)	v2(기본): 900 kW 37 → 18, 850 kW 765 → 392, 800 kW 3,282 → 2,493 kWh(코디네이터 끔 → 켬). v1 → v2: 최악의 날 절감 9.8 → 15.9%이나 한도 초과 시간은 폭염 2,050 → 3,303분(8일 합계) 등으로 늘었고 초과 전력량은 줄었음(폭염 일평균 548 → 301 kWh)
수전 예측 (1시간 앞)	미래 날씨 미사용, n=766: CV(RMSE) 8.0%, NMBE −0.1%. 어제 같은 시각 9.7%, 1시간 전 값 유지 13.1%. ASHRAE 30%는 보정 기준이라 비교용
센서 고장 감지	기본 입력 오경보 0건/1,206 실·일 (무고장 25회 합계 6건/30,150, σ 0.3 °C 1건/1,206). 훈련 63/64 감지, 정밀도 98%(경보 진위를 아는 운영자 가정). 드리프트의 에너지 영향 +1,289 kWh(감지 끔) → +26(켬)

6.1 시나리오별 (8일 평균)

시나리오	비용 절감	최대 수전 (kW)	한도 초과 (분/일)	쾌적 (%)
평상시	17.4%	960 vs 1,170	0 vs 249.5	99.9 vs 100
폭염 (+5 °C)	15.4%	1,125 vs 1,392	412.9 vs 734	99.7 vs 99.3
흐린 날 (일사 25%)	14.3%	1,059 vs 1,258	62.3 vs 626.4	100 vs 100
수요반응 강화 (16시 300 kW·60분)	19.1%	962 vs 1,170	0 vs 249.5	99.5 vs 100
피크 한도 850 kW	17.3%	878 vs 1,170	148.9 vs 755.5	99.9 vs 100
퇴근길 EV +6대	17.9%	976 vs 1,267	0.1 vs 281.6	99.9 vs 100
휴일·방학 (재실 25%)	25.9%	898 vs 1,045	0 vs 45.1	99.2 vs 100
최악의 날 (복합)	15.9%	**1,299 vs 1,454**	668.6 vs 815.6	99.3 vs 100

수요반응 달성률(요청 대비 실제 감축): 평상시 139% vs 7%, 수요반응 강화 98% vs 2%, 최악의 날 86% vs 2%. 값은 코디네이터 v2(기본값) 기준이고 v1은 `scn_summary.json`에 있습니다.

6.2 AI 비서

항목	결과
v2.1 (데스크톱 Q8_0, 질문 문장은 학습에도 있음)	수치 검사 통과 98.9%(정확도 지표 아님), "한 문장으로" 지시 준수 100%, 답할 수 있는 질문 거절 0.4%. 제안(게이트웨이 필터 후): 효과 없는 조치 0건, 정밀도 74.7% · 재현율 70.0%, "바꿀 필요 없음" 37/37. 답 속도 중앙값 2.0초·0원(Claude 9-13초, 질문당 약 $0.037)
v2.1, 실제 질문 66개 (Claude 채점)	41.5 → **62점**, 오답 17 → **0** (질문 분류·데이터 조회·출력 점검 추가 후). 수정에 쓴 회귀 세트임
v2.1 대 v2.2 (새 문장 세트, 모델만)	현재 대시보드에서 새로 모은 학습 밖 세트: 채팅 759문항 수치 검사 통과 93.3 → **97.1%**, 답마다 정답에 없는 숫자 1.45 → **0.38**개. 제안 127건 정밀도/재현율 62.1/70.0 → **83.5/78.3%**. 바꿀 필요 없는 상태 94건에서 조치를 내지 않은 비율 9.6 → **87.2%**. 실제 예상 질문 47개 × 3회 점검 통과는 80.9 → **79.4%**로 조금 낮음(옛 스냅숏 6개 제외 92.7 → 91.1%). **알려진 오류**: "왜 배터리를 방전하고 있어?"에서 v2.2는 ESS 에이전트의 계획 방전량 175 kW를 현재 출력(실제 228.7 kW)으로 말해, 수치 검사가 경고를 붙임

7. 장점

장점	근거
공정한 비교 **같은 조건의 기준선**	매 분 같은 입력으로 룰 기반 BMS를 함께 돌려 차이만 봅니다. 9일·1분 단위로, 기준선을 튜닝 BMS·센서 BMS·BDG2 부하 형태로 바꿔도 10.5~17.4% 절감이 남습니다(센서 BMS는 쾌적 97.0%).
피크와 비용 **둘 다 줄임**	평상시 한도 초과 0분(BMS 1,996분), 일별 최대 수전의 평균이 210 kW 낮음. 시나리오 9종 중 비용을 따질 수 있는 8종 모두 14.3~25.9% 절감.
설명 가능 **"왜"가 보임**	에이전트마다 조치와 이유를 결정 로그에 남기고, 코디네이터가 받은 제안·가격·배정이 보입니다. AI 답에는 수치 검사 결과가 붙고, 검증·근거 탭에 방법·한계·출처가 있습니다.
사람이 최종 결정	AI 제안은 적용 버튼을 눌러야 실행되고, 범위(22-28 °C)와 데이터센터 냉방 보호를 페이지가 다시 검사합니다. 고장 경보도 승인 카드로 처리합니다.
운영 기능의 폭	실 단위 재실 제어(절감 기여 13.4%p), ESS 피크 깎기, 수전 예측(CV(RMSE) 8.0%), 고장 감지(기본 입력 오경보 0건), DR 자동 대응, EV 충전 미루기를 한 화면에서.
로컬 AI	운영 데이터가 PC 밖으로 나가지 않고 질문당 비용이 0원입니다. 파인튜닝(v2.1) 후 수치 검사 통과 98.9%(정확도 지표 아님), 실제 예상 질문 62/66점·오답 0건(수정에 쓴 회귀 세트).
쉬운 접근과 재현	설치 없이 브라우저에서 동작하고 무료(GitHub Pages + Cloudflare)로 공개했습니다. 평가 스크립트·결과·어댑터가 공개 저장소에 있고, 시나리오 9종과 사용자 정의 조건으로 다시 돌려 볼 수 있습니다.

8. 단점과 한계

한계	내용과 영향
시뮬레이션 기준	절감은 실제 계량 데이터로 보정하기 전 값입니다. 냉방 시즌(여름)만 다루고, 겨울 난방과 한전 겨울철 두 번의 최대부하 시간대는 모델에 없습니다.
기본요금 제외	기본 비용은 전력량요금만 계산합니다. 기본요금(8,320원/kW·월)을 기간 최대에 곱해 따로 넣으면 한전 요금 15.7 → 16.2%, BDG2 14.7 → 15.7%입니다.
코디네이터의 효과	평소 한도에서는 코디네이터의 배분 단계가 추가 절감을 만들지 않습니다(–0.16%p; 이 실험은 협상·비용 배분만 끄고, 배터리 예측 운전과 DR 사전 냉방은 계획에 남김). 한도가 빠듯할 때만 초과 전력을 줄입니다(900 kW –52%, 850 kW –49%, 800 kW –24%; v1은 –13%, –21%, –9%).
최악의 날 약점	복합 상황에서 v1의 평균 최대 수전은 BMS보다 58 kW 높았습니다(1,512 vs 1,454. 배터리가 14시쯤 바닥나고 DR 직후 냉방이 한꺼번에 복귀). 기본값이 된 v2는 1,299 kW로 BMS보다 낮추지만, 한도를 넘는 시간은 오히려 늘었고(3,557 → 5,349분, 8일) 폭염(2,050 → 3,303분)·한도 800(2,059 → 3,867분)에서도 늘었습니다(넘은 전력량은 줄었음). EV 몰림의 평균 최대 수전(960 → 976 kW)과 평상시 DR 이행(142 → 139%)도 v1보다 나빠졌습니다.
약간의 쾌적 손해	쾌적 유지율이 99.9%(DR 시나리오 99.4%)로 BMS의 100%보다 조금 낮습니다. 사전 냉방·완화를 쓰는 대가입니다.
모델링 범위	센서 고장의 에너지 영향은 선택 모드(faultImpact)에서만 시험했고(방치한 고착은 불쾌 +1,963 °C·h, 닫힌 루프 드리프트 감지 55 → 245분), EV·태양광 지표는 지금 시나리오에서 두 방식의 차이가 거의 없어 변별력이 없습니다.
로컬 AI의 한계	8B 모델은 학습하지 않은 유형의 질문에 약해, 질문 분류·데이터 조회로 보완했습니다. v2.2에는 위의 ESS 문구 오류가 남아 있고, 현재 대시보드의 맥락 형식에 기대 옛 맥락에서는 조치를 거의 제안하지 않습니다. v2.1의 부분 정답 8개는 엉뚱한 보조 줄(숫자는 데이터에 있어 검사 통과)이었고, 같은 질문도 실행마다 답이 조금씩 다릅니다. 로컬 제안은 빈 방 소등·셋백 위주이고 그래픽 메모리를 약 10 GB 씁니다.
배포 방식	AI는 운영자 PC가 켜져 있어야 동작합니다. Quick Tunnel은 테스트용이라 주소가 매번 바뀌고 응답이 한 번에 옵니다(스트리밍 없음). 2026-11-10 밤에는 네트워크 끊김으로 스스로 종료돼 다시 켰습니다. 접근 키는 직접 나눠 줘야 합니다.
유지보수	대시보드가 약 1 MB 단일 HTML 파일이고 빌드 스크립트가 모듈을 끼워 넣는 구조라, 여럿이 나눠 고치거나 단위 테스트하기 어렵습니다.

9. 다음 단계

할 일	기대 효과
실측 데이터로 보정	실제 건물 계량·BEMS 데이터로 부하 모델을 맞춰, 절감 수치를 "시뮬레이션 기준"에서 실측 기반으로
기본요금·겨울철 반영	피크 저감의 금전 가치와 난방 시즌·겨울 요금 시간대까지 비용 계산에 포함
코디네이터 v2의 한도 초과 시간 줄이기	폭염·최악의 날·한도 800에서 한도를 넘는 시간이 v1보다 길어짐(스트레스 시나리오)
AI v2.2의 ESS 문구 고치기	계획 방전량과 실제 출력을 구분하는 예시로 다시 학습해 같은 세트로 확인(운영 PC 등록은 2026-11-12에 마침)
대시보드 캡처 새로 찍기	발표자료·README의 캡처는 v2 기본값 이전 수치(예: 예측 11.0%, 절감 16.7%)를 담고 있음
상시 운영용 연결	자체 도메인 + 이름 있는 터널로 고정 주소, 터널 감시·자동 재시작

부록

A. 폴더 구조 (원본 저장소)

폴더·파일	내용
`index.html`	대시보드(빌드 결과물)
`build/`	대시보드 모듈 원본(AI 탭, 요금, 고장 감지, 검증·시나리오 탭)과 `inject.py`
`server/`	게이트웨이 `mabems_server.py`, 질문 처리 `assist.py`, 수치 검사 `numcheck.py`
`eval/`	성능 평가 재현 방법과 결과표
`ft/`	로컬 LLM 파인튜닝: 데이터 생성·학습·평가, 실제 질문 세트 `data/realq.json`
`deploy/`	공개 모드 켜기·끄기, 사이트 배포, 접근 키 관리 스크립트
`HANDOFF.md`	인수인계: 현재 상태, 결정 이유, 명령

B. 실행 방법

- **보기만**: 공개 사이트 sunghyunc.github.io/ma-bems 를 엽니다(설치 없음).
- **내 PC에서 AI까지**: Ollama를 켜고 `.venv\Scripts\python server\mabems_server.py` → http://127.0.0.1:5178
- **공개 모드**: `deploy\start-public.cmd`(게이트웨이 + 터널 + 사이트 주소 갱신), 끄기 `deploy\stop-public.cmd`
- **수정 후 배포**: `python -I build\inject.py` → `deploy\publish-site.cmd`

C. 용어

용어	뜻
BEMS / BMS	건물 에너지 관리 시스템 / 건물 설비 자동제어 시스템. 여기서 "룰 기반 BMS"는 시간표·고정 설정으로 움직이는 비교 기준
수전, 피크 한도	한전 계통에서 받는 전력(kW)과 계약한 최대치. 한 번 높게 찍힌 피크가 최대 1년간 기본요금을 올림
계시별 요금(TOU)	시간대마다 kWh 단가가 다른 요금(경부하·중간부하·최대부하)
ESS	에너지 저장 장치(대형 배터리). 싼 시간에 충전, 비싼 시간·피크에 방전
DR(수요반응)	전력회사가 정한 시간 동안 사용량을 줄여 달라고 요청하는 제도. 줄인 만큼 보상
셋백	빈 공간의 설정온도를 완화해(여름엔 높여) 공조 에너지를 줄이는 것
FDD, 가상 센서	고장 감지·진단. 가상 센서는 설정온도와 이웃 방 오차로 추정한 대체 온도
CV(RMSE), NMBE	예측 오차 지표. ASHRAE Guideline 14의 시간 단위 기준은 CV(RMSE) 30% 이하, NMBE ±10% 이내
QLoRA, 파인튜닝	큰 언어모델의 일부 가중치만 저비용으로 추가 학습해 특정 업무에 맞추는 방법